조수연 교수

공학생을위한실용AI

3주차. AI를 위한 데이터

1강. 거대 데이터와 사전 학습



영진전문대학교에서 수업 자료로 사용되는 (동영상, 교안) 저작물은『저작권법 제25조 학교교육 목적 등에의 이용』의거하여, 적법하게 이용하고 있습니다.
수업목적 이외의 사용은 저작권법에 저촉될 수 있으므로 수업자료(동영상, 교안)의 대중 공개 , 공유 , 복제 , 전송 등 수업목적 외의 사용을 금지합니다.

학습내용 및 학습목표

학습내용

1. AI와 거대 데이터
2. LLM 학습의 3단계
3. 사전 학습

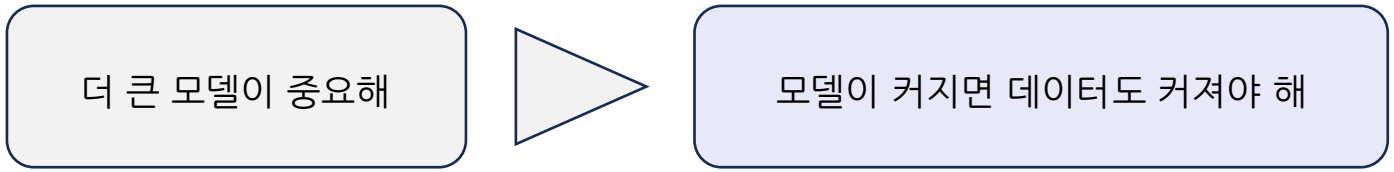
학습목표

1. AI 학습의 단계를 설명할 수 있다.
2. AI 학습에서 데이터의 중요성을 설명할 수 있다.
3. AI의 사전 학습 원리를 설명할 수 있다.

1. AI와 거대 데이터 (1)

1) 데이터 중심의 AI 시대

- 모델 구조(Architecture) 보다는 '어떤 데이터로 학습했는가?" 가 경쟁력
- 모델이 커질수록, 더 많은 데이터가 필요함
- 친칠라 최적 비율 (Chinchilla Optimal - 2022)
  - DeepMind 팀의 논문에서 소개
  - 이전까지는 모델의 사이즈를 키우는 것이 주요 방향이었다면 데이터의 양이 모델과 함께 늘어야 성능이 더욱 좋아짐을 발견



출처 01 arXiv - 친칠라 최적 모델 논문

1. AI와 거대 데이터 (2)

2) 거대 데이터

- 지금의 인공지능은 거대 데이터가 필요함

모델 이름	파라미터 수(추정치/공개치)
GPT-4	약 1조 8천억 개 (추정치)
GPT-3	1,750억 개
Llama 3	8B, 70B, 405B
Claude 3.5 Sonnet	약 1,750억 개(추정치)

출처 02 GPt-3

출처 03 Llama

1. AI와 거대 데이터 (3)

3) 데이터의 원천

- 데이터의 실제 비중은 각 AI 연구소의 비밀

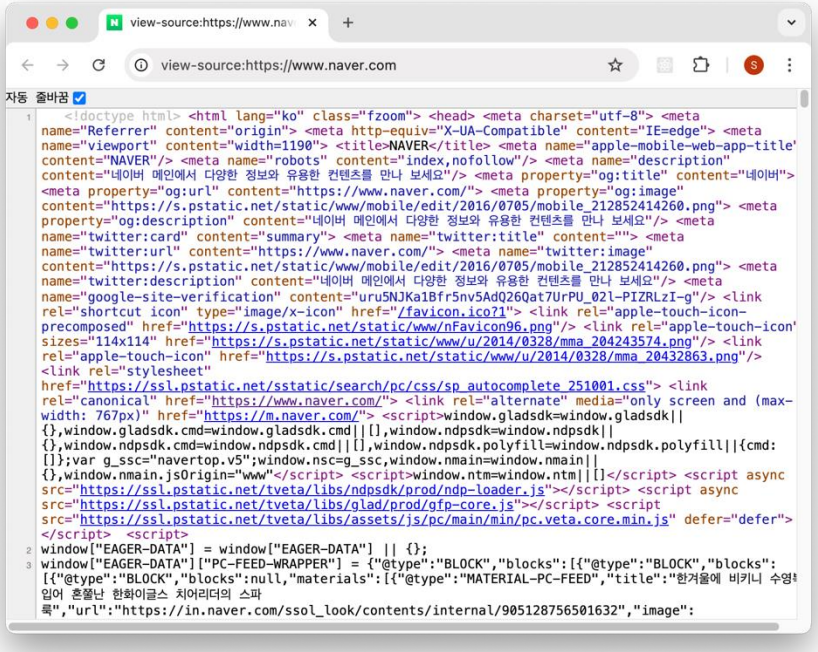
데이터의 원천	주요 역할	비중 (Llama 3 기준)
웹 데이터	보편적 지식, 상식, 트렌드	60-70%
책/논문	전문 지식. 고급 문법	약 20%
코드	논리적 추론 능력	약 10-15%

출처 04 Llama 논문

1. AI와 거대 데이터 (4)

4) 데이터의 원천 - 웹 데이터

- 웹 크롤링 (Web Crawling)
- 전세계 인터넷 웹 페이지에서 모은 거대 데이터. 뉴스, 블로그 등을 포함
- 언어 학습, 광범위한 지식 습득
- 가짜 뉴스, 혐오 포현, 광고등이 혼재되어 있음



https://www.naver.com 의 소스보기 화면
웹 데이터의 실체는 HTML 문자열

1. AI와 거대 데이터 (5)

5) 데이터의 원천 - 책

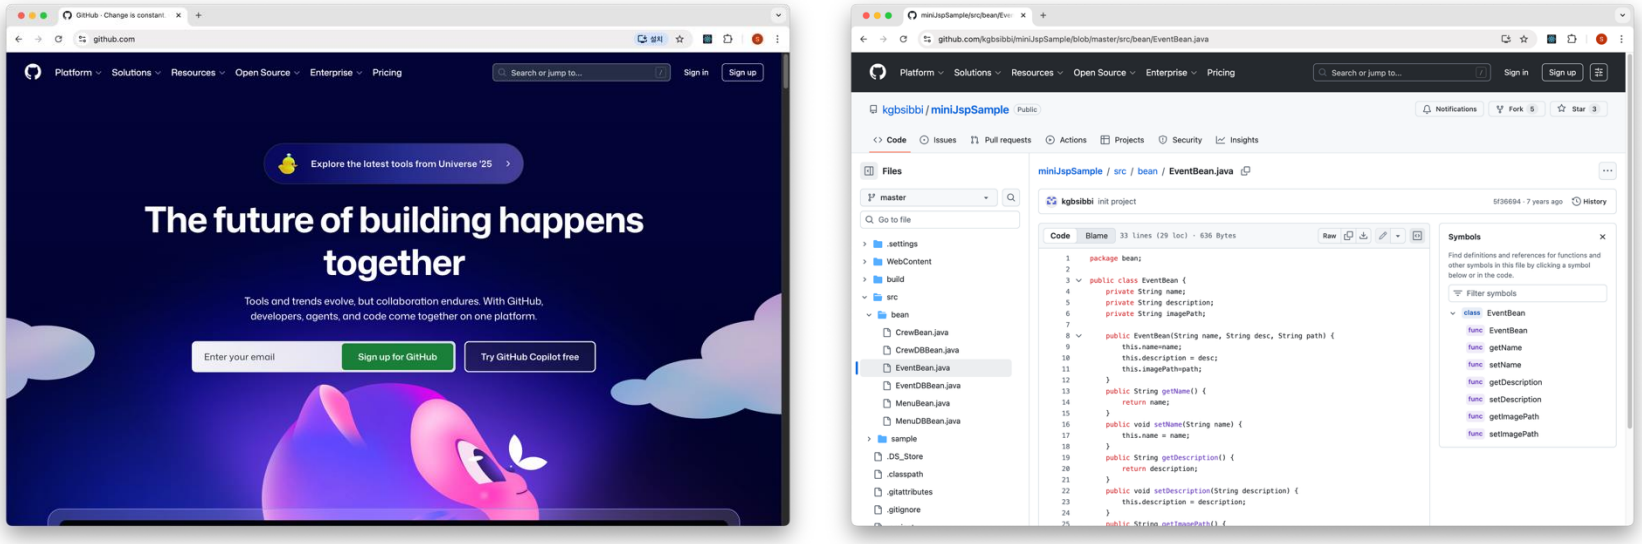
- 조각난 웹의 지식과 달리 한 주제에 대한 완결된 지식 제공
- 체계적인 서술
- 잘 정제된 문장을 제공하여 고급 언어 학습에 사용 가능

- 많은 책들이 디지털화 되면서 학습용 데이터로 활용할 수 있게 됨

1. AI와 거대 데이터 (6)

6) 데이터의 원천 - 코드

- Github 등에서 얻을 수 있는 소프트웨어 코드를 학습
- 논리적 구조가 엄격한 코드를 통해 단계적 추론을 학습



github 코드의 일부

출처 05 Github

1. AI와 거대 데이터 (7)

7) 데이터 고갈

- 2026년 경 인류가 생성한 고급 텍스트 데이터가 고갈 될 것이라는 예측
- 합성 데이터(Synthetic Data)가 대안.
  - 인간이 생성한 데이터를 모방한 인간이 생성하지 않은 데이터
  - 무제한 데이터 생성, 프라이버시 보호 등의 장점
  - 부분 합성 데이터, 완전 합성 데이터
  - 교통 시뮬레이션, 금융 시뮬레이션, 의료 등의 분야에서 활용 가능
  - 편향성, 데이터 품질 의존성, 현실성 부족 등의 부작용이 있을 수 있음
- 멀티 모달
  - 이미지, 영상, 소리 데이터를 활용

출처 06 데이터 고갈

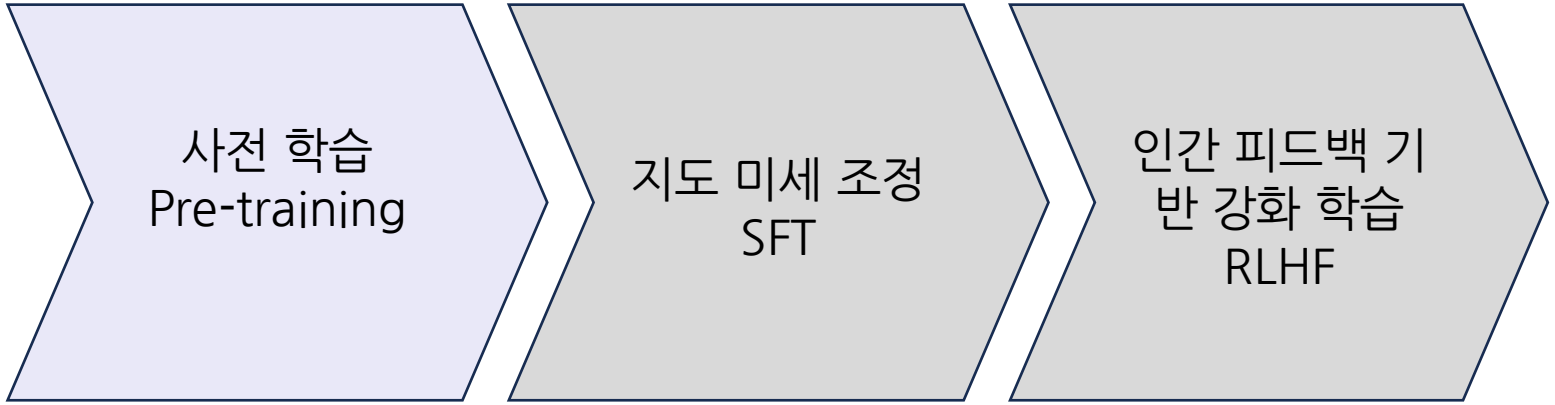
출처 07 AWS - 합성 데이터

출처 08 IBM - 합성 데이터

2. LLM 학습의 3단계

1) LLM 학습의 3단계

- OpenAI 연구팀에서 제안한 LLM 학습 단계
- LLM은 다음과 같은 단계를 거쳐 모델이 생성된다.



출처 09 LLM 학습 단계

3. 사전 학습 (1)

1) 지식의 압축

- 인터넷 전체 데이터를 100GB 정도의 모델 파일에 넣기 위해선?
  - 단순 암기는 불가능
  - 원리와 패턴을 적용해야 효과적으로 압축 가능

- 챗GPT 는 웹의 흐릿한 JPEG
  - 테드 창 - ChatGPT Is a Blurry JPEG of the Web
  - 원본 이미지를 압축하여 저장한 다음 다시 보여주는 JPEG 와 같이 챗GPT는 웹의 정보를 압축한 것

  - 참고 - JPEG는 손실 압축의 한 종류

출처 10 테드 창

출처 11 JPEG

3. 사전 학습 (2)

2) 사전 학습

- 사람이 정답을 주는 것이 아닌 스스로 학습
- 사전 학습용 데이터의 전처리
  - 데이터 정제
    - 원본 데이터를 그대로 사용하지 않고 학습할 수 있는 고품질의 데이터로 변환하는 과정
  - 토큰화
    - 단어를 그대로 사용하면 어휘가 너무 많고 철자 단위로 사용하면 문맥 파악이 어렵기 때문에 사용 빈도가 높은 조합을 하나의 단위- 토큰으로 묶음
- 전처리 된 데이터를 활용 스스로 학습
  - 이 때 GPU를 활용

3. 사전 학습 (3)

3) 데이터 정제

- 중복 데이터 제거
  - 중복 데이터가 많으면 문장을 암기하게 됨
  - 새로운 상황에 대처하지 못하게 됨

- 품질 필터링
  - 단어의 반복이 너무 많은 글 - 주로 광고나 스팸
  - 대부분이 특수문자인 글 - 깨진 글
  - 불용어(Stopwords)의 비중이 너무 높거나 낮은 글
  - 성인물, 도박, 혐오 표현이 포함된 글

- 개인 정보 제거



3. 사전 학습 (4)

4) 토큰화 (Tokenization)

- 단어를 그대로 읽지 않고 '토큰'이라는 단위로 숫자로 변환

Hello | World

- 토큰화 방식에 따라 AI의 이해 효율과 비용이 결정
- LLM의 동작은 다음에 올 단어(토큰)의 계산

"대한민국의 수도는 ?"

서울 : 98.2%
부산 : 0.8%
도쿄 : 0.1%

3. 사전 학습 (5)

5) 사전 학습이 끝나면?

- 한국의 수도는? 이라는 질문에 "서울입니다."가 올 확률이 높다는 것을 알게 됨
- 문법에 맞는 문장을 구성할 수 있음
- 코딩, 수학, 번역 등에 대한 능력을 가지게 됨

- 그러나 대화용으로 튜닝 되지는 않은 상태. 질문에 답을 하기보다는 높은 확률의 다음 문장을 이어가게 됨

정리하기

1. AI와 거대 데이터

- 성능 좋은 AI를 위해서는 모델과 데이터가 함께 필요.
- 현대의 AI는 거대 데이터를 요구함.

2. LLM 학습의 3단계

- 사전학습 -> 지도 미세 조정 -> 인간 피드백 기반 강화 학습.

3. 사전 학습

- 웹, 도서, 코드 등을 원천 데이터로 하여 스스로 학습.
- 대화형 AI를 위한 준비 단계.

다음시간에는

3주차 2강. 고품질 데이터와 가치 정렬

에 대해 학습해 보겠습니다.

출처안내 (1)

출처	비고
1	• 조던 호프만 외 (2022). arXiv "Training Compute-Optimal Large Language Models" https://arxiv.org/abs/2203.15556
2	• 위키 백과 "GPT-3" https://ko.wikipedia.org/wiki/GPT-3
3	• Meta ai 사이트(2024). "Introducing Meta Llama 3: The most capable openly available LLM to date" https://ai.meta.com/blog/meta-llama-3/
4	• Meta ai 사이트(2024). "The Llama 3 Herd of Models" https://ai.meta.com/research/publications/the-llama-3-herd-of-models/
5	• Github https://github.com 및 개인 코드 저장소 https://github.com/kgbsibbi/miniJspSample 에서 캡쳐함
6	• 이경탁(2025-11-04) 조선일보. ""더 이상 학습할 데이터가 없다"… 박사급 성능 멀어지는 '챗GPT'" https://biz.chosun.com/it-science/ict/2025/11/04/MIDZ4TG4FJBZHLB2DJ2XJNVB3A/
7	• 아마존 AWS 공식 사이트(연도미상) "합성 데이터란 무엇인가요?" https://aws.amazon.com/ko/what-is/synthetic-data/
8	• Rina Diane Caballar(연도미상) IBM Think. "합성 데이터란 무엇인가요?" https://www.ibm.com/kr-ko/think/topics/synthetic-data
9	• Long Ouyang 외(2022) arXiv "Training language models to follow instructions with human feedback" https://arxiv.org/abs/2203.02155

출처안내 (2)

출처	비고
10	• 테드 창(2023). The New Yorker "CHATGPT IS A BLURRY JPEG OF THE WEB" https://www.newyorker.com/tech/annals-of-technology/chatgpt-is-a-blurry-jpeg-of-the-web
	• 위키 백과 "JPEG" https://ko.wikipedia.org/wiki/JPEG