조수연 교수

# 공학생을위한실용AI

## 3주차. AI를 위한 데이터

## 2강. 고품질 데이터와 가치 정렬




영진전문대학교에서 수업 자료로 사용되는 (동영상, 교안) 저작물은『저작권법 제25조 학교교육 목적 등에의 이용』의거하여, 적법하게 이용하고 있습니다.
수업목적 이외의 사용은 저작권법에 저촉될 수 있으므로 수업자료(동영상, 교안)의 대중 공개 , 공유 , 복제 , 전송 등 수업목적 외의 사용을 금지합니다.

# 학습내용 및 학습목표

## 학습내용

1. LLM 학습의 3단계
2. 미세 조정
3. 가치 정렬

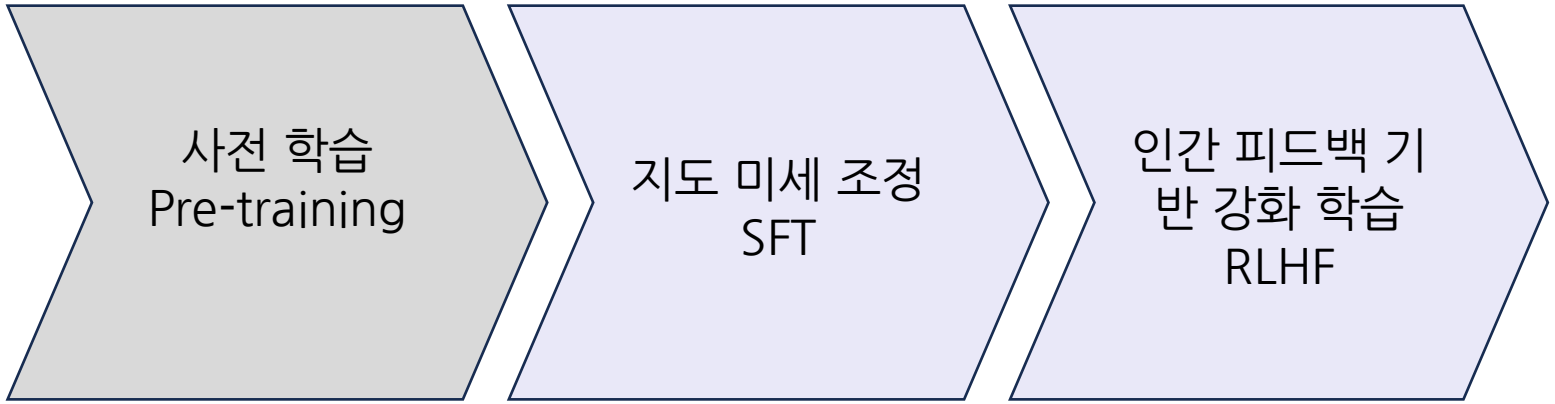
## 학습목표

1. 미세 조정의 개념을 설명할 수 있다.
2. 가치 정렬의 개념을 설명할 수 있다.

# 1. LLM 학습의 3단계

## 1) LLM 학습의 3단계

- 사전 학습으로 방대한 지식을 습득
- 지도 미세 조정과 인간 피드백 기반 강화 학습으로 대화형 AI로 동작하게 됨
- Long Ouyang 외(2022) "Training language models to follow instructions with human feedback"




출처 01 LLM 학습 단계

# 2. 미세 조정 (1)

## 1) 기본 모델의 한계

- 사전 학습을 마친 모델은 다음에 올 단어를 잘 추측하는 문장 이어 쓰기 엔진
- 질문에 대한 대답이 아니라 확률이 높은 유사한 문장을 나열

**프롬프트**: 대한민국의 수도는 어디야?
**답변**: 대한민국의 수도는 서울입니다. 독일의 수도는 베를린입니다. 영국의 수도는 런던입니다.

- 지식은 있지만 아직은 대화하는 법을 모름
- 비서로서의 모습은 정렬(Alignment)이 필요함

# 2. 미세 조정 (2)

## 2) 정렬 (Alignment)

- 사전 학습을 통해 얻은 '지식'을 인간의 의도와 가치, 그리고 안전한 가이드라인에 부합하도록 조정하는 과정
- 지식 - 사전 학습의 데이터는 통계적 정보. 유해한 내용이 포함될 수 있음
- 태도 - 사용자의 목적을 정확히 이행하며 도움이 되는 답변을 제공해야 함

- 방대한 지식을 지닌 야생의 지능을 인간이 사용할 수 있는 형태로 조정하는 작업

# 2. 미세 조정 (3)

## 3) 미세 조정 (SFT)

- Supervised Fine-Tuning
- 사람이 작성한 질문과 정답 세트를 학습시켜 '질문에 답하는 법'을 가르침

**프롬프트**: 대한민국의 수도는 어디야?
**답변**: 대한민국의 수도는 서울입니다.

- 얼마나 많은 데이터가 필요한가?
  - 52,000개의 데이터 셋 보다 1,000개의 고품질 데이터 셋이 선호도에서 승리
  - 전문가가 검수한 정답지가 AI의 성능을 끌어올림 - LIMA 가설

출처 02 LIMA 가설

# 2. 미세 조정 (4)

## 4) 미세 조정 데이터의 품질 기준

- 정확성
  - 잘못된 정보를 제공할 경우 모델은 해당 내용을 진실로 인식
  - 당당하게 틀린 정보를 대답하게 됨

- 다양성
  - 수학, 글쓰기, 코딩, 요약 등 다양한 지시문을 포함

- 복잡성
  - 단순 질문보다는 단계별 추론이 필요한 복합 질문데이터

# 2. 미세 조정 (5)

## 5) 미세 조정 (SFT)의 결과

- 질문, 답변의 대화 구조를 가지는 비서로서의 모습 완성
- 페르소나 주입 - 일관된 톤앤매너 유지

너는 전문적이면서도 친절한 요리 선생님이야.

너는 전문적이고 논리적인 프로그래머야.

# 2. 미세 조정 (6)

## 6) 미세 조정의 한계

- 사람이 작성함으로써 발생하는 문제점들
- 비용 문제 - 고수준의 데이터 셋을 만드는데 수억~수십억 원 이상 소요
- 모순 학습 - 작성자마다 답변 스타일이 다르면 모델은 혼란을 겪음

# 3. 가치 정렬 (1)

## 1) 가치 정렬 (Reinforcement Learning from Human Feedback)

- 처음에는 비디오 클립 선택 에서 시작
  - 좀 더 간단하고 인간이 선호도를 반영하는 방법으로 제안
  - 둘 중 하나를 고르기

- SFT 데이터를 사람이 직접 만들기 때문에 비용이 많이 들고 모든 정답을 다 제공할 수는 없음
- AI의 답변 중 무엇이 더 인간에게 유익하고 안전한지 인간이 투표하여 학습

**A 답변과 B 답변 중 어느 것이 더 도움이 되시나요?**

- 인간은 정답을 작성하는 것은 어려워도 둘 중 고르는 것은 쉬움

출처 03 비디오 클립 선택 논문

# 3. 가치 정렬 (2)

## 2) 단계 1 : 비교 데이터 셋

- 질문 하나에 여러 개의 답변을 생성한 뒤 인간이 답변의 순위를 매김
  - 인간의 선호도에 대한 기초 자료

**프롬프트**: 점심 메뉴 추천해 줘.
**답변 A**: 샐러드.
**답변 B**: 건강을 생각하신다면 샐러드를 추천합니다.

이 경우 대부분의 선택은 답변 B
단순 정보보다 **친절함과 맥락**이 중요함을 알게 됨

# 3. 가치 정렬 (3)

## 3) 단계 2 : 보상 모델 학습

- 보상 모델(Reward Model) 학습
  - 인간이 수많은 질문에 일일이 선호도를 입력 하기엔 시간과 비용이 많이 소요
  - 인간 선호도를 학습하여 답변을 인간이 얼마나 좋아할 지 출력하는 별도의 AI모델 준비
    - 대답을 입력하면 얼마나 좋아할 지에 대한 수치를 알려줌
  - 사람 없이 보상 모델이 메인 모델을 채점

# 3. 가치 정렬 (4)

## 4) 단계 3 : 강화 학습 최적화

- 강화 학습 최적화
  - Main AI가 답변을 생성하면 보상 모델이 점수를 채점.
  - 높은 점수를 받기 위해 답변 전략을 수정

- PPO - Proximal Policy Optimization Algorithms
  - AI의 행동 방식을 업데이트할 때 너무 과격하게 변하지 않도록 하면서 안정적으로 성능을 올리는 알고리즘

- 결과적으로 인간의 가치에 정렬하게 됨

출처 04 PPO

# 3. 가치 정렬 (5)

## 5) 가치 정렬의 기준 - 3H

- **Helpful**
  - 답변은 유용해야 하며 질문자의 의도에 맞아야 함
- **Honest**
  - 모르는 것은 모른다고 하고 환각을 줄여야 함
- **Harmless**
  - 사회적 편향, 증오 표현 및 위험한 정보를 제공하지 않아야 함

출처 05 3H의 정의

# 3. 가치 정렬 (6)

## 6) 보상 해킹

- 보상 모델의 허점을 파고들어 점수만 높게 받는 증상

"정중한 말투면 높은 점수"라는 규칙을 발견하면 정중한 말투로 틀린 대답을 함

"마침표를 잘 찍으면 가산점을 준다"라는 규칙을 발견하면 틀린 대답에 마침표를 찍어 보상을 얻고자 함

출처 06 보상 해킹

# 3. 가치 정렬 (7)

## 7) 인간 피드백의 대체

- Constitutional AI
  - 인간 대신 'AI 헌법'을 아는 다른 AI가 모델을 채점하는 방식
    - 마땅히 지켜야 할 윤리적인 규칙들을 정해 학습
  - 인간 피드백 속도 한계 극복
  - 모델 스스로 자신의 답변을 비판하고 수정하게 유도
  - Claude 시리즈의 정렬 기술

# 3. 가치 정렬 (8)

## 8) 최신 트랜드

- DPO - Direct Preference Optimization
  - 직접 선호도 최적화
  - 복잡한 보상 모델 학습과 강화 학습 과정을 생략하자는 방법
  - 보상 모델 없이 선호 데이터를 확률 공식에 직접 대입하여 모델을 훈련

출처 08 DPO

출처 09 Azure DPO

# 정리하기

## 1. LLM 학습의 3단계

- 사전학습, 지도 미세 조정, 인간 피드백 기반 강화 학습이 있음

## 2. 미세 조정

- 질문에 답변할 수 있도록 인공지능을 조정하는 단계

## 3. 가치 정렬

- 인간의 선호도에 부합하면서 안전한 AI를 만들기 위한 단계.

다음시간에는

# 4주차 1강. LLM(거대언어모델) 개론

에 대해 학습해 보겠습니다.

# 출처안내

| 출처 | 비고 |
|---|---|
| 1 | • Long Ouyang 외(2022) arXiv "Training language models to follow instructions with human feedback" https://arxiv.org/abs/2203.02155 |
| 2 | • Chunting Zhou 외 (2023) arXiv "LIMA: Less Is More for Alignment" https://arxiv.org/abs/2305.11206 |
| 3 | • Paul Christiano 외 (2017) arXiv "Deep reinforcement learning from human preferences" https://arxiv.org/abs/1706.03741 |
| 4 | • John Schulman 외(2017) arXiv " Proximal Policy Optimization Algorithms" https://arxiv.org/abs/1707.06347 |
| 5 | • Amanda Askell 외(2021) arXiv "A General Language Assistant as a Laboratory for Alignment" https://arxiv.org/abs/2112.00861 |
| 6 | • Joar Skalse 외 (2022) arXiv "Defining and Characterizing Reward Hacking" https://arxiv.org/abs/2209.13085 |
| 7 | • Yuntao Bai 외 (2022) arXiv "Constitutional AI: Harmlessness from AI Feedback" https://arxiv.org/abs/2212.08073 |
| 8 | • Rafael Rafailov 외(2023) arXiv "Direct Preference Optimization: Your Language Model is Secretly a Reward Model" https://arxiv.org/abs/2305.18290 |
| 9 | • Microsoft Azure 학습 사이트 https://learn.microsoft.com/ko-kr/azure/ai-foundry/openai/how-to/fine-tuning-direct-preference-optimization?view=foundry-classic |