조수연 교수

공학생을위한실용AI

4주차. LLM 개론

1강. LLM(거대언어모델) 개론



영진전문대학교에서 수업 자료로 사용되는 (동영상, 교안) 저작물은『저작권법 제25조 학교교육 목적 등에의 이용』의거하여, 적법하게 이용하고 있습니다.
수업목적 이외의 사용은 저작권법에 저촉될 수 있으므로 수업자료(동영상, 교안)의 대중 공개 , 공유 , 복제 , 전송 등 수업목적 외의 사용을 금지합니다.

학습내용 및 학습목표

학습내용

1. 트랜스포머
2. 어텐션 메커니즘
3. 스케일링 법칙

학습목표

1. 트랜스포머의 원리를 설명할 수 있다.
2. 어텐션의 메커니즘을 설명할 수 있다.
3. 스케일링 법칙을 설명할 수 있다.

1. 트랜스포머 (1)

1) 트랜스포머

- 학습한 데이터가 식재료라면 트랜스포머는 주방의 기계장치

- 기존 방식(RNN)은 왼쪽에서 오른쪽으로 한 단어씩 읽는 방법
  - 병렬 처리 불가능. 연산이 오래 걸림
  - 문장이 너무 길어지면 앞 내용을 잊어버림

- Attention is all you need
  - 문장을 한번에 보고 중요한 부분에 주의(Attention)을 기울임

    지금 이 단어를 이해하려면 문장 속 어느 단어를 얼마나 참고해야 하지?

  - 트랜스포머는 문장 전체를 한눈에 확인. 정보를 잊지 않음

출처 01 Attention is all you need

1. 트랜스포머 (2)

2) 작업 1 - 토큰화 단계

- Tokenization
- 문장과 단어를 작은 조각으로 나누는 작업.
- 단어 하나가 더 작은 조각으로 나뉠 수 있음 - 자주 나오지 않는 단어에 대한 성능을 높임

I | am | a | high | school | stu | dent

- 나눈 각 단어를 숫자 ID로 변환

출처 02 자주 나오지 않는 단어 처리

1. 트랜스포머 (3)

3) 작업 2 - 임베딩

- Embedding
- 토큰에 부여된 번호(ID)는 공간 좌표로 변환됨 - 원 논문에서는 512차원

'왕'과 '여왕'은 가까운 곳에 위치

'사과'와 '배'도 가까운 곳에 위치

'사과'와 '자동차는' 먼 곳에 위치

출처 01 Attention is all you need

1. 트랜스포머 (4)

4) 작업 3 - 순서 정보 주입

- 문장을 한번에 보기 때문에 각 단어에 위치 정보를 주입

사과가 사람을 먹는다 — 사과 토큰 정보에 첫 번째 토큰이라는 정보를 합성

사람이 사과를 먹는다 — 사과 토큰 정보에 n 번째 토큰이라는 정보를 합성

- Sin, Cos 함수 등을 활용하여 수학적으로 계산

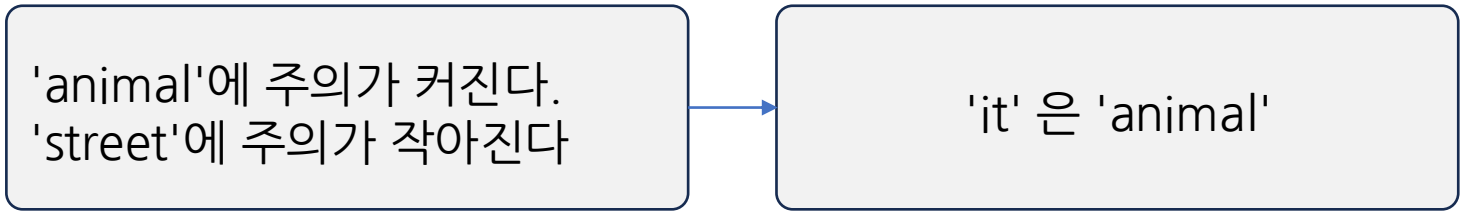
2. 어텐션 매커니즘 (1)

1) 어텐션

- 사람은 문장을 읽을 때 모든 단어를 똑같이 중요하게 생각하지 않음
- 그것(it)을 처리할 때 문장의 다른 단어 중 동물에 집중하여 관계를 파악

The **animal** didn't cross the street **because it** was too tired

- because 는 원인을 설명하는 신호 - 원인은 피곤
- 동물은 피곤할 수 있다. 길은 피곤하다와 어울리지 않는다.



2. 어텐션 매커니즘 (2)

2) 어텐션의 도구 - Q, K, V

- Q -Query 내가 지금 궁금한 것. 'it'
- K -Key. 문장의 각 단어들이 가진 특성 태그. "나는 이런 정보를 가진 단어"
- V - Value. 단어가 가진 진짜 의미

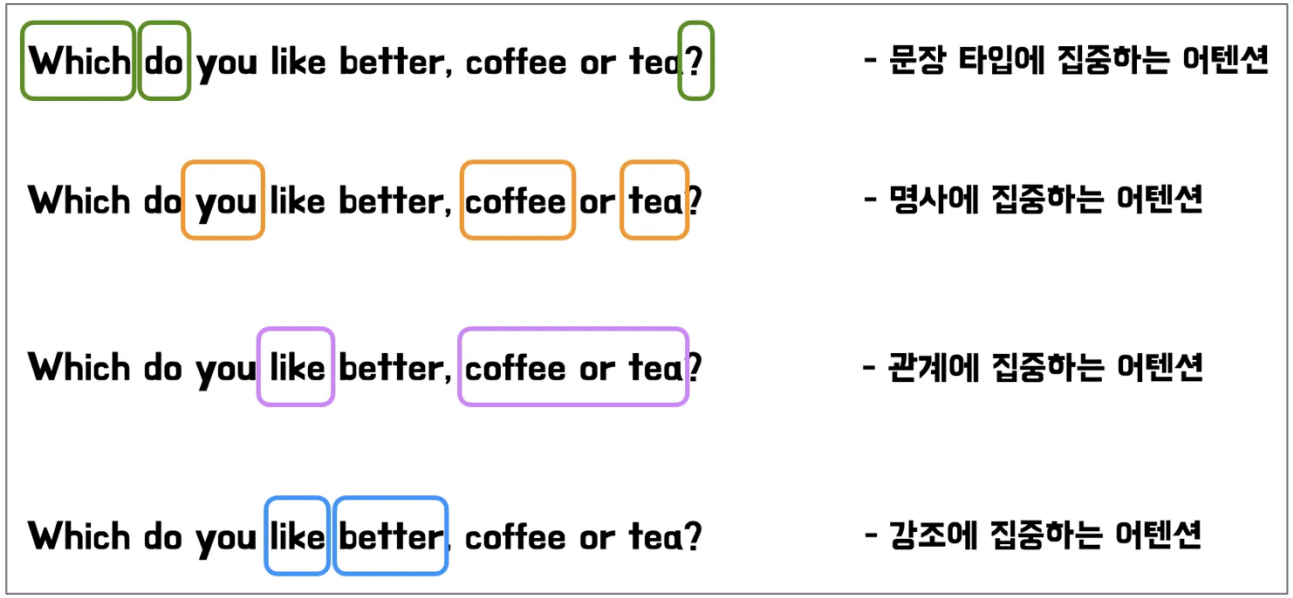
- 임베딩 + 순서 정보가 합쳐진 입력을 준비
- 점수 계산의 원리 - 수학적으로 두 토큰의 벡터 방향이 얼마나 일치하는지 확인
  - 내 질문(Q)와 다른 단어의 특성(K)가 얼마나 잘 맞는가?

- 방향이 비슷하면 관련성이 높다고 판단하여 높은 점수 부여

2. 어텐션 매커니즘 (3)

3) 멀티헤드 어텐션

- 문장을 한 번만 보는게 아니라 다른 관점으로 동시에 관찰
- 예를 들어



출처 03 멀티헤드 어텐션

3. 스케일링 법칙 (1)

1) 스케일링 법칙

- OpenAI - 모델의 크기를 키울수록 성능이 좋아짐을 발견

- 연산량 증가 -> 지능 상승
- 데이터 양 증가 -> 지능 상승
- 파라미터 수 -> 지능 상승

AI 빅테크의 조단위 투자



조선경제 > 테크

빅테크 내년 765조 AI 투자... 한국 국가 예산보다 많아

챗GPT 3년, 생존 전략 된 AI

유지한 기자 박지민 기자

업데이트 2025.11.24. 13:41

가

출처 04 Open AI의 논문

출처 05 위키백과 "신경망 스케일링 법칙"

출처 06 빅테크 투자액

3. 스케일링 법칙 (2)

2) 발현적 능력

- Emergent Abilities - 창발적 능력이라고도 함

> Emergence is when quantitative changes in a system result in qualitative changes in behavior.

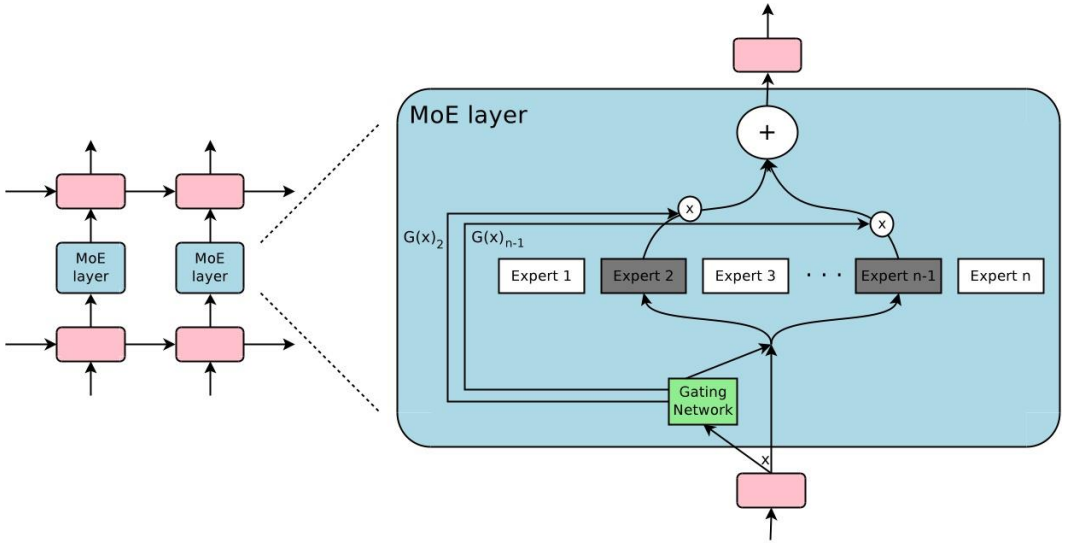
- 시스템 내의 양적인 변화가 시스템 동작의 질적인 변화를 불러일으킴
- 특정 규모가 되기 전의 AI가 특별한 능력이 없다가 일정 규모를 넘어선 순간 갑자기 추론, 코딩을 함

출처 07 발현적 능력

3. 스케일링 법칙 (3)

3) 전문가 혼합

- Mixture-of-Experts
- 모델이 너무 커지면 한 번 계산할 때마다 많은 비용이 소모
- MoE는 질문에 따라 필요한 부위만 활성화



출처 08 MoE

정리하기

1. 트랜스포머

- 문장을 한 번에 파악하는 메커니즘.

2. 어텐션 메커니즘

- 문장 내에 각 토큰의 가중치에 따라 판단. 집중해야 할 부분을 찾음

3. 스케일링 법칙

- 모델의 크기가 커질 수록 지능이 발현됨
- 큰 모델을 효율적으로 사용하기 위한 방법도 연구 진행

다음시간에는

4주차 2강. LLM의 현재와 미래

에 대해 학습해 보겠습니다.

출처안내

출처	비고
1	• Ashish Vaswani 등(2017). arXiv. "Attention Is All You Need" https://arxiv.org/abs/1706.03762
2	• Rico Sennrich 외 (2015) arXiv "Neural machine translation of rare words with subword units" https://arxiv.org/abs/1508.07909
3	• 이민경(2023-02-25) blossonminkyung.com "트랜스포머(Transformer) 파헤치기-2.Multi-Head Attention" https://www.blossominkyung.com/deeplearning/transformer-mha
4	• Jared Kaplan 외(2020) arXiv " Scaling Laws for Neural Language Models" https://arxiv.org/abs/2001.08361
5	• 위키백과 "신경망 스케일링 법칙" https://ko.wikipedia.org/wiki/신경망_스케일링_법칙
6	• 유지한(2025-11-24). 조선일보 " 빅테크 내년 765조 AI 투자... 한국 국가 예산보다 많아" https://www.chosun.com/economy/tech_it/2025/11/24/CMML5FB5HNCV7F63RWUOEBUY4I/
7	• Jason Wei외 (2022) arXiv "Emergent Abilities of Large Language Models" https://arxiv.org/abs/2206.07682
8	• Noam Shazeer외(2017) arXiv "Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer" https://arxiv.org/abs/1701.06538