조수연 교수

공학생을위한실용AI

4주차. LLM 개론

2강. LLM의 현재와 미래



영진전문대학교에서 수업 자료로 사용되는 (동영상, 교안) 저작물은『저작권법 제25조 학교교육 목적 등에의 이용』의거하여, 적법하게 이용하고 있습니다.
수업목적 이외의 사용은 저작권법에 저촉될 수 있으므로 수업자료(동영상, 교안)의 대중 공개 , 공유 , 복제 , 전송 등 수업목적 외의 사용을 금지합니다.

학습내용 및 학습목표

학습내용

1. 인공지능 모델 분석
2. 추론 메커니즘
3. 에이전트 기술

학습목표

1. 최신 모델의 종류와 특징을 설명할 수 있다.
2. 추론 메커니즘을 설명할 수 있다.
3. 에이전트 기술이 무엇인지 설명할 수 있다.

1. 인공지능 모델 분석 (1)

1) OpenAI: GPT-5 & GPT-5 Pro

- 대부분의 벤치마크에서 인간 박사 수준을 상회
- 장문작업이 향상 - 최대 256k 토큰
- 코딩 특화: GPT-5.2-Codex
- 멀티 모달
- 적은 할루시네이션

출처 01 GPT-5 소개

출처 02 GPT-5.2-Codex 소개

1. 인공지능 모델 분석 (2)

2) Anthropic: Claude 4.5

- Claude 4.5 Sonnet/Opus
- 코딩/에이전트 작업에 특화
- 수백만 토큰을 유지하면서 대규모 프로젝트 파일을 한 번에검토
- 설치 버전이 있으며 MCP 를 활용한 다양한 활용 가능

출처 03 Claude Opus 4.5 소개

1. 인공지능 모델 분석 (3)

3) Google: Gemini 3

- Pro/ Deep Think/Flash 등으로 세분화

  Flash: 비용과 지연 최적화. 빠른 응답

  Pro/Deep Think: 고난도 추론. 더 깊은 추론 모드

- 구글 생태계와 통합

  작업물을 구글 독스로 내보내기 등

- 코드, 텍스트, 이미지등을 통합하여 처리
- 엔비디아 없이 Gemini 3 개발

출처 04 Gemini Flash 소개

출처 05 Google TPU

1. 인공지능 모델 분석 (4)

4) Meta: Llama 4

- 전 세계 기업용 AI 생태계의 표본
  - 기업 내 클라우드에 직접 배포. 데이터를 외부에 공개하지 않을 수 있음
  - 커스터마이징이 용이
  - 다양한 사이즈로 모델이 배포되어 용도에 맞게 선택 가능
- MoE, 멀티모달, 장문 컨텍스트를 핵심으로 소개
- 모바일 및 로컬 서버에서 구동 가능한 초경량 버전 동시 공개

출처 06 Llama4 소개

2. 추론 매커니즘 (1)

1) 생각의 사슬: Chain of Thought

- 복잡한 질문에 대해 정답을 바로 내기 전에 추론 과정을 생성하도록 유도하는 기술

- 특별한 예시 없이 "단계별로 생각하라"는 문구로 추론 성능이 올라감
- 오류를 범했을 때 다음 토큰 생성 과정에서 수정할 기회를 얻음

- 최신 모델은 사용자가 시키지 않아도 내부적으로 수천 개의 사고 경로를 검토함
  - 정답에 도달하는 논리의 단계에 보상을 받으며 훈련
  - AI 스스로 여러 경로로 문제를 풀어보고 오류가 나면 되돌아감
  - 최신 모델에서 답변까지 몇 초 걸리는 이유

출처 07 Chain of Thought

2. 추론 매커니즘 (2)

2) CoT가 작동하는 이유

- 트랜스포머 구조는 한 토큰을 생성할 때 고정된 연산을 수행
- CoT를 통해 중간 단계를 많이 출력하면 모델은 더 많은 연산을 수행
  - 중간 단계의 토큰이 다음 단계의 입력이 됨
- 정교한 결과를 도출

3) 문제점

- 단계가 길어져도 오답이 나올 수 있음
- 토큰이 늘면 비용이 늘어남

3. 에이전트 기술 (1)

1) RAG - 1

- Retrieval-Augmented Generation

- LLM의 모델은 과거의 데이터로 학습된 모델.
- 확률적으로 환각이 있을 수 있음

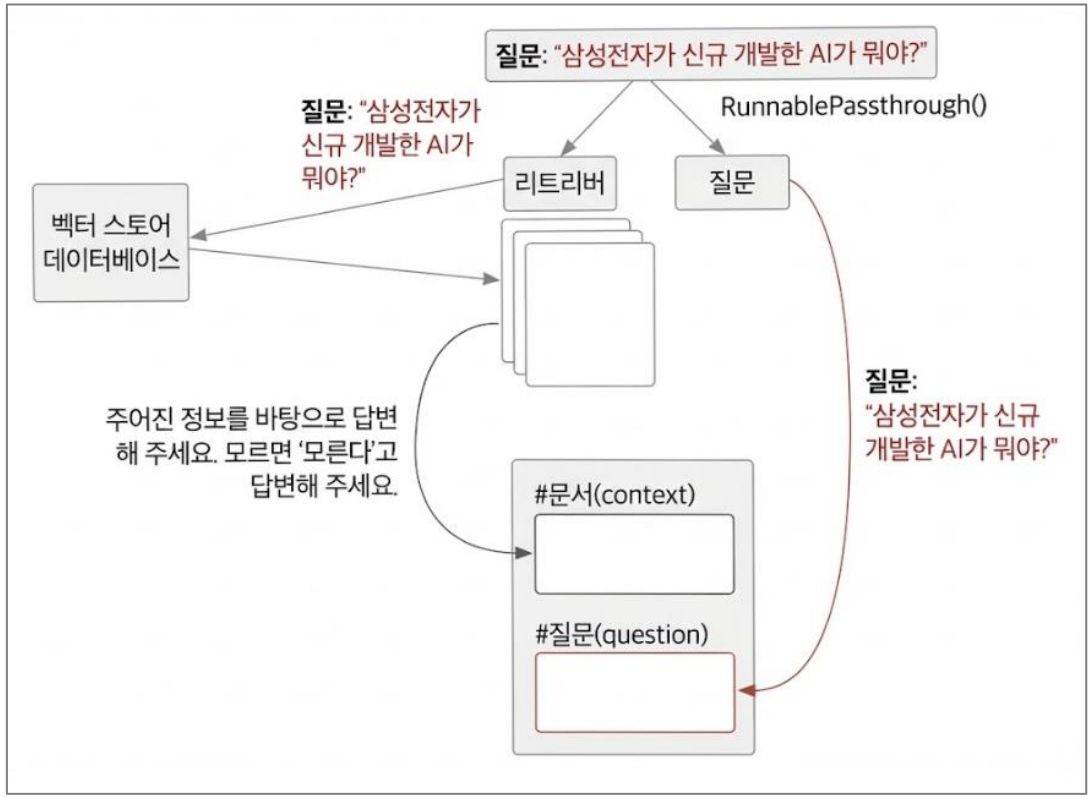
- 실제 문서를 바탕으로 답하도록 하자!
  - 실제 문서를 검색이 용이한 형태로 가공한 뒤 사용자가 질문할 때 관련된 실제 문서를 찾아서 LLM에게 주면서 질문
  - 문서를 그대로 저장할 경우 용량도 많고 검색에 너무 많은 시간이 걸림

출처 08 RAG

3. 에이전트 기술 (2)

2) RAG - 2

- Retrieval-Augmented Generation



이경록(2025) 리코멘드 테디노트의 랭체인을 활용한 RAG 비법노트(기본편) 40페이지

3. 에이전트 기술 (3)

3) MCP - 1

- Model Context Protocol

- LLM은 과거의 데이터로 학습된 모델
- AI에게 특정 데이터를 전달하거나 도구를 사용할 수 있도록 하여 최신 정보를 얻도록 하고자 함 -> 도구까지 직접 다룰 수 있어야 에이전트라 할 수 있음

- 문제는 호환성과 보안

  각 소프트웨어나 외부 데이터들과 각각 연결할 경우는 호환성이 문제
  내가 허락한 데이터만 AI가 접근했으면 하는 상황

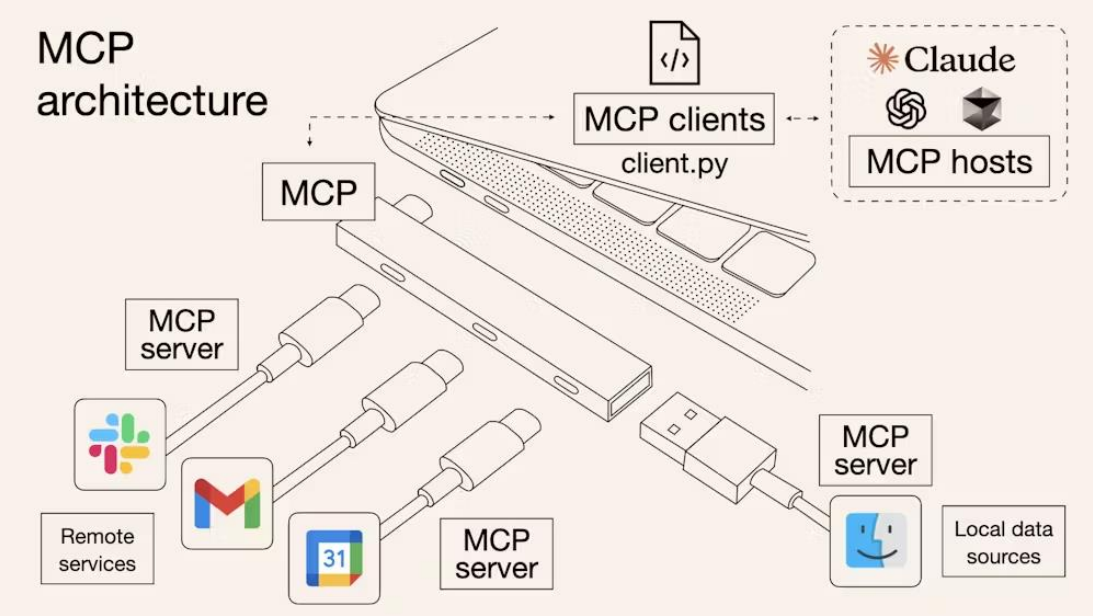
출처 10 MCP 사이트

출처 11 위키백과 "모델 컨텍스트 프로토콜"

3. 에이전트 기술 (4)

4) MCP - 2

- Model Context Protocol
- 다양한 소프트웨어와 AI를 즉시 연결하는 표준



출처12 MCP

3. 에이전트 기술 (5)

5) 에이전트

- 목표를 달성하기 위해 스스로 계획하고 도구를 사용하는 단계

바탕화면에 있는 파일 중에서 만든지 1년 지난 파일은 삭제해 줘

주소록에 있는 A 씨에게 메일 보내줘

- Claude가 제안한 MCP
- 구글이 구축 중인 다양한 도구 통합

AI + RAG + MCP + 앞으로의 그 무엇

정리하기

1. 인공지능 모델 분석

- 모델이 정교해지고 추론이 강화되는 추세
- 저비용의 모델도 함께 연구됨

2. 추론 메커니즘

- 생각의 사슬을 통한 더 많은 연산으로 정교한 답을 찾음

3. 에이전트 기술

- 모델에게 최신 정보를 제공하기 위한 노력이 이루어짐
- 복잡한 여러 단계의 업무를 수행하는 에이전트도 발전 중임

다음시간에는

5주차 1강. 프롬프팅의 기초

에 대해 학습해 보겠습니다.

출처안내 (1)

출처	비고
1	• OpenAI(2025-08-07) "GPT-5를 소개합니다" https://openai.com/ko-KR/index/introducing-gpt-5/
2	• OpenAI(2025-12-18) "Introducing GPT-5.2-Codex" https://openai.com/index/introducing-gpt-5-2-codex/
3	• Anthropic(2025-11-25) "Introducing Claude Opus 4.5" https://www.anthropic.com/news/claude-opus-4-5
4	• Google Product News(2025-12-17) "Gemini 3 Flash: frontier intelligence built for speed" https://blog.google/products/gemini/gemini-3-flash/
5	• 조성미(2025-11-26) 연합뉴스 "엔비디아 없이 제미나이3 만든 구글…TPU로 AI 판도 흔들(종합)" https://www.yna.co.kr/view/AKR20251126059351017
6	• Meta(2025-04-05) "The Llama 4 herd: The beginning of a new era of natively multimodal AI innovation" https://ai.meta.com/blog/llama-4-multimodal-intelligence/
7	• Jason Wei 외 (2022) arXiv "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models" https://arxiv.org/abs/2201.11903
8	• Shangyu Wu 외(2024) arXiv "Retrieval-Augmented Generation for Natural Language Processing: A Survey" https://arxiv.org/abs/2407.13193
9	• 이경록(2025)"테디노트의 랭체인을 활용한 RAG 비법노트(기본편)" 리코멘드. 40.

출처안내 (2)

출처	비고
10	• Model Context Protocol https://modelcontextprotocol.io/docs/getting-started/intro
11	• 위키백과 "모델 컨텍스트 프로토콜" https://ko.wikipedia.org/wiki/모델_컨텍스트_프로토콜
12	• Victor(2025-06-04) DEVOCEAN(SK그룹 개발자 커뮤니티) "USB-C처럼 연결되는 AI 인터페이스, MCP Server를 만들어보자" "https://devocean.sk.com/blog/techBoardDetail.do?ID=167498&boardType=techBlog